



Trabajo Práctico 02

Clasificación y selección de modelos

16 de junio de 2025

Laboratorio de Datos

Marcel Mango

Integrante	LU	Correo electrónico
Rabinovitz, Martin	52/24	<code>martinr0905@gmail.com</code>
Ballester, Lucas	391/24	<code>lucaskasparbal@gmail.com</code>
Paz Curtet, Lautaro	294/24	<code>lautaro.paz.curtet@gmail.com</code>
Trucillo Biglieri, Renato	337/24	<code>renatrucillo8@gmail.com</code>



Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (+54 11) 4576-3300

<http://www.exactas.uba.ar>

Resumen

En este trabajo práctico se aborda el uso de técnicas de clasificación supervisada aplicadas al dataset **Fashion-MNIST**, que contiene imágenes de prendas clasificadas en 10 categorías. El objetivo principal es **entrenar, evaluar y comparar** modelos de clasificación, con foco en la selección de modelos e hiperparámetros mediante validación cruzada. El trabajo se dividió en tres partes:

- El análisis exploratorio inicial, que reveló las particularidades visuales y la variabilidad de las clases.
- Una clasificación binaria entre las clases 0 y 8 utilizando KNN sobre distintos subconjuntos de atributos, donde se observó la crucial influencia de la selección de atributos en el desempeño del modelo.
- Clasificación multiclase con árboles de decisión, donde se probaron distintas profundidades y configuraciones, destacando que la validación cruzada fue clave para seleccionar un modelo robusto, aunque se identificaron confusiones persistentes entre clases visualmente similares.

Introducción

Problemática

El problema de clasificación multiclase consiste en predecir a qué clase pertenece una observación entre más de dos posibles categorías. En este caso, se busca asignar correctamente cada imagen de ropa del dataset Fashion-MNIST a una de las 10 clases disponibles, cada una representando un tipo distinto de prenda. Esto implica que el modelo debe ser capaz de aprender a distinguir patrones visuales sutiles entre categorías similares, lo cual representa un desafío mayor que en la clasificación binaria.

Objetivo general

El objetivo general de este trabajo es aplicar técnicas de clasificación supervisada para desarrollar modelos que permitan predecir la clase de una prenda de ropa a partir de imágenes, utilizando el dataset Fashion-MNIST. Se busca evaluar distintas estrategias de modelado, analizar su desempeño mediante métricas apropiadas y seleccionar el mejor modelo utilizando validación cruzada y experimentación controlada.

Actividades a realizar

- Realizar un análisis exploratorio del dataset Fashion-MNIST, identificando características relevantes de los atributos e imágenes, y evaluando posibles similitudes y diferencias entre clases.
- Abordar un problema de clasificación binaria entre dos clases seleccionadas, aplicando el algoritmo KNN con diferentes configuraciones de atributos y valores de k .
- Formular un problema de clasificación multiclase con las 10 clases del conjunto original, evaluando modelos de árbol de decisión con distintas profundidades e hiperparámetros.
- Utilizar validación cruzada para seleccionar el mejor modelo y evaluar su desempeño sobre un conjunto independiente de validación.
- Analizar los resultados obtenidos mediante métricas de clasificación y visualizar errores.

Análisis Exploratorio de Datos

En esta sección se realiza un análisis exploratorio del dataset Fashion-MNIST con el objetivo de conocer su estructura, distribución y características de los atributos, identificando cuáles podrían ser relevantes para tareas de clasificación automática.

Dimensiones y estructura del dataset:

- Cada imagen tiene una resolución de 28 x 28 píxeles, lo que resulta en 784 atributos numéricos por imagen, correspondientes a los valores de intensidad en escala de grises de cada píxel (valores entre 0 y 255).

- Además, cada fila del dataset incluye una etiqueta ('label') que indica la clase a la que pertenece la imagen, siendo un número entero entre 0 y 9. Cada número corresponde a un tipo distinto de prenda (por ejemplo, 0: camiseta, 1: pantalón, etc.), como se observa en la figura 1




Figura 1: Ejemplo de imágenes para cada clase

- El dataset Fashion-MNIST contiene 70.000 imágenes distribuidas equitativamente entre las 10 clases, con 7.000 imágenes por clase. Esto garantiza un problema balanceado desde el punto de vista de clasificación, lo cual es beneficioso para la evaluación y entrenamiento de modelos.

Atributos relevantes para clasificación

relevante para identificar la clase a la que pertenece cada imagen, naturalmente es la etiqueta (*label*). Sin embargo, para el diseño de modelos de clasificación, se busca que esta predicción pueda realizarse exclusivamente a partir de los valores de los píxeles.

Los siguientes atributos que parecen más relevantes son los valores de los píxeles periféricos al centro de la imagen, el sector central superior y el sector central inferior. Podemos ver por la Figura 2 (heatmap IQR por píxel) que estos píxeles en concreto tienen una alta variación entre sus valores y, por lo tanto, es más probable que en estos haya diferencias entre clases.




Figura 2: Heatmap de IQR por píxel de todas las imágenes

Por otro lado, en el heatmap notamos que los píxeles de las esquinas tienen valores cercanos a 0 (negro), lo que indica que podrían no ser informativos para la distinción. Sin embargo, encontramos patrones interesantes de ciertas clases que rompen esta generalidad:

- Para las clases 5 (Sandal), 7 (Sneaker) y 9 (Ankle boot) notamos que las puntas de los calzados siempre apuntan hacia la izquierda y, por lo tanto, los píxeles del cuadrante superior izquierdo pueden ser buenos candidatos, ya que en esa región se presentará una mayor cantidad de píxeles negros (esto se ve claramente en la imagen 1).

Similitudes y diferencias entre clases

Para analizar visualmente las similitudes y diferencias entre las clases, se generaron imágenes promedio a partir del valor promedio de cada píxel dentro de cada clase (Figura 3). Estas imágenes permiten observar las formas características de cada tipo de prenda, sin tener distorsiones de los ejemplos individuales.




Figura 3: Valor promedio por píxel por clase

A partir de las imágenes promedio (figura 3) notamos diferencias marcadas entre algunas clases. Por ejemplo:

- Entre la clase 1 (Trouser) y la clase 2 (Pullover): La imagen promedio de la clase 1 presenta una silueta vertical y estrecha, claramente diferenciable de la clase 2, en la cual se nota una forma más ancha con mangas visibles.

Para poder analizar las diferencias entre ambas clases, se generó un heatmap IQR por píxel de las imágenes de la clase 1 y clase 2 (Figura 4a) para ver gráficamente en qué píxeles hay una mayor variabilidad. A partir de la imagen, vemos que hay una gran área (mangas y zona inferior) de la figura en la cual el IQR de los píxeles es alto, arriba de 150, lo cual nos indica que la distinción entre clase 1 y clase 2 será sencilla.




Figura 4: (a) IQR por píxel de clases 1 y 2 (b) IQR por píxel de clases 2, 4 y 6

- Entre clase 2 (Pullover), clase 4 (Coat) y clase 6 (Shirt): Las imágenes promedio de las 3 clases presentan formas similares, un torso ancho y mangas a los costados de éste (Figura 4b).

Siguiendo los mismos pasos que para comparar clase 2 y clase 1, se generó un heatmap IQR por píxel de las imágenes de clases 2, 4 y 6 (Figura 4b). En dicho gráfico, notamos que la mayoría de los píxeles presentan un valor de IQR relativamente bajo (entre 75 y 125), concentrados en la zona central de las imágenes (torsos y mangas de las prendas).

Esto indica que hay menor variabilidad entre estas clases en esas regiones clave, lo cual sugiere que será más difícil para un modelo distinguir entre ellas.

En resumen, si bien algunas clases como la 1 (Trouser) y la 2 (Pullover) presentan diferencias marcadas tanto en la imagen promedio como en los niveles de variabilidad por píxel, lo que facilita su distinción, existen grupos de clases —como la 2, 4 y 6— cuyas imágenes comparten características visuales similares. Esta similitud se refleja en sus imágenes promedio y en los valores de IQR por píxel en regiones clave, lo cual puede dificultar su correcta clasificación. Por lo tanto, el nivel de dificultad para distinguir entre clases varía significativamente dentro del dataset, dependiendo de cuán visualmente similares sean las prendas representadas.

Variabilidad interna dentro de una clase

Para analizar la variabilidad interna de una clase, se tomó como ejemplo la clase 8 (Bag). Al observar diferentes imágenes de esta clase (Figura 5a), se nota una importante diversidad visual: si bien todos los elementos corresponden a bolsos, varían en forma, tamaño, orientación y detalles.

Esta observación se respalda con el mapa de calor del IQR por píxel (Figura 5b), donde se evidencia alta variabilidad en los bordes y zonas externas, lo que indica diferencias en las siluetas y contornos de los objetos. En contraste, el centro de las imágenes presenta menor variabilidad.

A pesar de estas diferencias, se detectan ciertos patrones comunes, como formas mayormente rectangulares o cuadradas, y regiones oscuras centrales que podrían corresponder a huecos.

Esto sugiere que, aunque la clase 8 presenta alta variabilidad interna, existen características compartidas que podrían ser aprovechadas por modelos de clasificación para aprender a identificarla correctamente.




Figura 5: (a) Ejemplos de bolsos (b) IQR por píxel de la clase 8.

A diferencia de otros datasets, por ejemplo el de los pasajeros supervivientes del accidente del Titanic, en los que las variables tienen un significado directo y es más interpretable a simple vista, el dataset Fashion-MNIST está organizado de distinta manera. Cada imagen está representada por 784 atributos, uno por cada píxel, lo que complica la exploración de los datos con herramientas estándar como histogramas o boxplots.

Particularidades de Fashion-MNIST

Además, los atributos individuales no tienen un significado semántico trivial. Saber que un píxel tiene un valor de 200 o 230 en escala de grises no aporta información útil por sí solo, a diferencia de lo que ocurre con variables numéricas en datasets convencionales. Esta falta de intuición, sumada a la gran cantidad de filas, hace que los métodos clásicos de exploración y análisis no resulten tan útiles para obtener conclusiones claras.

Por este motivo, la exploración del dataset requiere enfoques específicos para datos visuales, como la reconstrucción de imágenes a partir de los píxeles, la visualización de promedios por clase o el análisis de variabilidad a través de heatmaps de IQR.

Clasificación binaria entre clases 0 y 8 con K-Nearest Neighbors

En esta sección del trabajo práctico se desarrollarán los procesos para realizar una clasificación binaria utilizando un subconjunto del dataset Fashion-MNIST, centrado en distinguir entre imágenes de la clase 0 (T-shirt/top) y la clase 8 (Bag). El objetivo es entrenar y evaluar modelos de vecinos más cercanos (KNN), considerando, en una primera instancia, la selección de conjuntos de atributos con $K = 3$; y luego, en una segunda instancia, probando distintos valores de K . Para todos los experimentos se utilizó la distancia euclídeana (la aplicada por defecto).

Selección de subconjunto y análisis de balanceo

Comenzamos por filtrar el dataset original para conservar solamente las instancias correspondientes a las clases 0 y 8. Este nuevo dataset cuenta con 14.000 imágenes: 7000 de clase 0 y 7000 de clase 8. Podemos decir que este nuevo conjunto está **balanceado**, ya que ambas clases están representadas en igual cantidad, lo que nos permite entrenar modelos sin sesgos por clase mayoritaria.

Realizamos una separación de los datos en train y test. Se separó al 80 % (11200 imágenes) para entrenar al modelo y el 20 % (2800) restante para evaluar al mismo.

Métricas de evaluación

Para la evaluación de los distintos modelos en los experimentos, se consideraron las siguientes métricas:

Leyenda para entender las fracciones:

XX : número de instancias de clase X clasificadas correctamente

XY : número de instancias de clase X clasificadas erróneamente como clase Y

YX : número de instancias de clase Y clasificadas erróneamente como clase X

$X, Y \in \{0, 8\}$, indican la clase.

- **Exactitud:** $\frac{00 + 88}{08 + 80}$ Para evaluar la efectividad general de las predicciones del modelo. No se separó en exactitud por clases pues la exactitud en ambos casos es igual.
- **Precisión de la clase 0:** $\frac{00}{00 + 08}$ Proporción de clasificaciones correctas que se hizo sobre la clase 0.
- **Exhaustividad (Recall) de la clase 0:** $\frac{00}{00 + 80}$ De las clasificadas como 0, proporción de cuántas son realmente 0.
- **Precisión de la clase 8:** $\frac{88}{88 + 08}$ Proporción de clasificaciones correctas que se hizo sobre la clase 8.
- **Exhaustividad (Recall) de la clase 8:** $\frac{88}{88 + 08}$ De las clasificadas como 8, proporción de cuántas son realmente 8.

Se eligieron estas métricas para poder realizar un análisis informado de la efectividad generalizada, la efectividad sobre cada clase y la tendencia entre tipos de errores de los modelos con respecto a la elección de atributos y la cantidad elegida de vecinos. No se consideró que una clase sea mejor que la otra, ni que un tipo de error sea preferible al otro.

Como el dataset se encuentra perfectamente balanceado (50 % clase 0 y 50 % clase 8), no se tuvo consideraciones con respecto al sesgo que pueda haber entre métricas con respecto al peso de cada clase, pues es equivalente para ambas.

Entrenamiento de modelo KNN, con $K = 3$ y conjuntos de 3 atributos




Figura 6: (a) Conjuntos de 3 atributos (b) IQR por píxel de las clases 0 y 8.

Con el objetivo de entender el desempeño del modelo **KNN** con $k = 3$, usando una cantidad reducida de atributos, diseñamos diversas combinaciones de tres píxeles, visualizadas en la figura 6a, teniendo en consideración la dispersión sobre la imagen de los atributos y el heatmap de IQR por píxel de la figura 6b.

Entrenamiento de modelo KNN, con $K = 3$ y conjuntos de distintos números de atributos




Figura 7: Conjuntos de atributos de varios píxeles

Para la selección de conjuntos de varios atributos, se eligieron subconjuntos de 12, 9 y 6 píxeles de distintas formas, buscando nuevamente cubrir diferentes zonas de las imágenes, teniendo en consideración el IQR por píxel (figura 6b).

Entrenamiento de modelo KNN, K variable

Para este experimento se eligieron los siguientes valores de K : 3, 9, 15, 21, 27, 33 y 39. Con respecto a los conjuntos de atributos se utilizaron algunos de los conjuntos utilizados en el punto anterior, todos de distinta cardinalidad: *3D* (3 píxeles, figura 6a); *C1* (9 píxeles), *Dispersos 12 px* (12 píxeles), *Fila medio* (6 píxeles) los últimos 3 presentes en la figura 7.

En cuanto a métricas, se decidió utilizar Exactitud y Media Armónica (F1) para cada clase, para informar como cambia la calidad predictiva general y sobre cada clase en específico con respecto al número de vecinos.

Conclusiones de clasificación binaria con KNN, $K = 3$ con conjuntos de 3 atributos y de más cantidades

Nombre conjunto	Exactitud	Precisión(0)	Recall(0)	Precisión(8)	Recall(8)	Nombre Conjunto	Exactitud	Precision(0)	Recall(0)	Precision(8)	Recall(8)
3A	0.663	0.664	0.661	0.663	0.665	Esquinas 12px	0.541	0.521	0.988	0.885	0.094
3B	0.854	0.845	0.866	0.862	0.841	Dispersos 12px	0.955	0.958	0.951	0.951	0.959
3C	0.849	0.824	0.886	0.877	0.811	Columnas 12px	0.914	0.917	0.911	0.911	0.917
3D	0.876	0.885	0.864	0.867	0.887	C1 9px	0.937	0.945	0.928	0.929	0.946
3E	0.84	0.825	0.862	0.856	0.817	C2 9px	0.672	0.653	0.731	0.695	0.612
3F	0.773	0.76	0.799	0.788	0.747	C3 9px	0.787	0.771	0.817	0.806	0.758
3G	0.61	0.603	0.646	0.619	0.574	Dispersos 6px	0.93	0.925	0.936	0.935	0.924
3H	0.856	0.866	0.842	0.846	0.869	Fila medio 6px	0.863	0.855	0.874	0.871	0.852

(a)
(b)

Figura 8: (a) Métricas para conjuntos de 3 atributos (b) Métricas para conjuntos de varios atributos

Experimento KNN, $K = 3$ con conjuntos de 3 atributos

Por las métricas calculadas y visibles en la figura 8a, se puede ver que los conjuntos con mejores exactitudes son los conjuntos *3D*, *3H* y *3B*, en ese orden. El conjunto *3D* supera por 0.2 en exactitud al *3H*, siendo claramente el más exacto de los conjuntos. Sus 3 píxeles coinciden con la zona superior de la imagen donde el IQR de los píxeles es alto (figura 6b). Debido a que *Precisión(0)* es más grande que *Recall(0)* y que *Recall(8)* es más grande que *Precisión(8)* se puede inferir que el error más común con este conjunto de atributos es el error de tipo *80*; es decir, el modelo tiende a clasificar instancias de la clase 8 como instancias de la clase 0.

Cabe destacar que el conjunto *3E* también está ubicado en la zona superior central pero no alcanzó los niveles de exactitud de *3D*, lo que podría indicar que los conjuntos de atributos subsecuentes no son tan útiles para predecir la clase de una instancia. Este argumento es reforzado por el hecho de que el conjunto *3G* también es un conjunto de píxeles subsecuentes y es el segundo peor de los conjuntos en cuanto a exactitud.

Otra observación es que *3C* posee las medidas *Recall(0)* y *Precisión(8)* más altas de los conjuntos, de lo que se infiere que estos atributos son buenos para detectar instancias de la clase 8 correctamente.

Experimento KNN, $K = 3$ con conjuntos de varios atributos

Se utilizarán las métricas de la figura 8b para realizar el análisis sobre los conjuntos de la figura 7.

La primera y más obvia observación es que la cantidad de atributos por sí sola no garantiza un buen desempeño del modelo; pues el conjunto *Esquinas 12px* está compuesto por 12 atributos con una exactitud muy cercana a 0.5. Sus métricas *Recall(0)*, cercana al 1, y *Recall(8)*, cercana al 0, delatan que el modelo está categorizando a casi todas las instancias dentro de la clase 0.

La segunda observación a hacer es que el cuadrado *C2* es un conjunto malo para predecir entre ambas clases, lo que coincide con la hipótesis de que las áreas de píxeles bajos en IQR no son buenas para predecir la clase de la instancia.

Analizando la exactitud entre los cuadrados *C1*, *C2* y *C3*, se puede ver que la zona de más alto valor con respecto a la calidad de las predicciones es la zona superior por una amplia diferencia. Observando las métricas de ambas clases se puede inferir que, en el caso de *C1* los errores del tipo *80* son más comunes; pero en los casos de *C2* y *C3*, el error *08* es bastante más prominente, lo que indica un sesgo en las predicciones con estos atributos hacia la clase 8.

el conjunto *Fila medio*, por otra parte, mezcla píxeles de bajo IQR y de alto IQR del centro de la imagen. Su exactitud indica nuevamente que el IQR de los píxeles del conjunto es importante, pues es posible que los 4

píxeles con IQR más altos estén compensando a los 2 píxeles del centro de bajo IQR. Como sucede que $Precisión(0)$ es mayor a $Recall(0)$ y $Precisión(8)$ es mayor a $Recall(8)$ para *Fila medio* y *C2*, se puede decir que los modelos que evalúan los píxeles del medio son más propensos a equivocar instancias de la clase 0 por instancias de la clase 8.

Los 3 mejores conjuntos con respecto a la exactitud del modelo son *Dispersos 12px*, *Dispersos 6px*, *Columnas 12px*. Los 3 coinciden en tener buena presencia en zonas de IQR alto, pero *Columnas 12px* tiene mejor distribución sobre estas que *Dispersos 6px*, lo que sugiere que la distancia entre los píxeles dentro del conjunto pueda ser un factor importante para garantizar un buen modelo predictivo. Con respecto a los errores, los 3 conjuntos presentan un buen balance entre estos, siendo la diferencia entre precisión y recall en cada clase de 0.007, 0.011 y 0.006 respectivamente.

0.1. Clasificación binaria con modelo KNN, K variable en conjuntos de atributos de distinta cantidad




Figura 9: Exactitud con K variable sobre conjuntos 3D, Dispersos 12px, Columnas y Fila medio




Figura 10: (a) Precisión sobre la clase 0 según valor de K (b) Precisión sobre la clase 8 según valor de K

Se puede observar a simple vista que la tendencia en las 3 métricas con respecto a la cantidad de atributos y el valor de k es muy parecida.

Los conjuntos de mayor cantidad de atributos (*Dispersos 12 px* y *C1 9px* figura 7) alcanzan su pico en $K = 9$, para luego estabilizarse hacia valores ligeramente más bajos en todas las métricas

El conjunto *Fila medio 6 px* tiene también su pico en métricas con $k = 9$, pero luego decrece constantemente, sugiriendo una relación inversa con el valor de k.

Por último, el conjunto de menor cantidad de atributos, *3D 3px* presenta una relación positiva con respecto al valor de K, llegando a su pico en las 3 métricas con $K = 27$ y luego estabilizándose en valores cercanos.

Clasificación Multiclase

En esta sección del trabajo práctico se abordará el problema de clasificación multiclase utilizando el dataset completo de Fashion-MNIST, con el objetivo de predecir a cuál de las diez clases pertenece una imagen dada. Se trabajará con modelos de árbol de decisión, explorando distintas configuraciones mediante validación cruzada sobre un conjunto de desarrollo, mientras se reserva un conjunto held-out para la evaluación final. Se analizará cómo afectan al desempeño del clasificador los hiperparámetros del árbol, en particular su profundidad, y se reportarán métricas de desempeño como la exactitud y la matriz de confusión.

Separación en conjuntos

Como primer paso separamos el conjunto de datos original en un **conjunto de desarrollo dev** (80 %) y un **conjunto evaluación held-out** (20 %). Esta separación nos permite reservar un conjunto que no participa en la selección de modelos para usarlo luego para una evaluación más realista del desempeño final.

Entrenamiento con diferentes profundidades

Sobre el conjunto de desarrollo entrenamos **modelos de árboles de decisión** con profundidades que van del 1 al 10. El objetivo en esta etapa fue observar cómo se comporta el modelo a medida que aumenta su capacidad (profundidad) en términos de exactitud sobre los datos de entrenamiento.

Como se esperaba, la exactitud crece rápidamente con las primeras profundidades y luego se estabiliza (Figura 11).




Figura 11

Validación cruzada para Selección de Modelo

Para seleccionar el mejor modelo, realizamos un experimento de validación cruzada con **k-folding** sobre el conjunto de desarrollo. Ésta metodología, en la que evaluamos el rendimiento promedio de cada modelo nos permitió estimar de forma **robusta** cuál es la profundidad que generaliza mejor, sin depender de una única partición de los datos.

El modelo óptimo fue aquel con profundidad igual a 10, que obtuvo el mejor *score* promedio en la validación cruzada.

Evaluación en ambos conjuntos de datos

Finalmente entrenamos el modelo elegido con su mejor profundidad sobre el conjunto de desarrollo, y lo evaluamos sobre el conjunto **held-out**, obteniendo una exactitud de aproximadamente 0,8052. Luego mediante la visualización de la matriz de confusión, pudimos observar en que clases el modelo tiene más errores y si hay confusiones sistemáticas entre clases similares (Figura 12). Por ejemplo: entre las clases Pullover y Coat o T-shirt/top y Shirt




Figura 12

Conclusiones

En este trabajo práctico, hemos abordado el problema de clasificación de imágenes de prendas de vestir del dataset Fashion-MNIST, utilizando técnicas de aprendizaje supervisado. El análisis exploratorio inicial nos permitió comprender la naturaleza del dataset, destacando la importancia de enfoques visuales debido a la gran cantidad de atributos de píxeles y su falta de significado semántico individual. Se observó que, si bien existen diferencias claras entre algunas clases que facilitan su distinción, otras presentan similitudes visuales que representan un desafío mayor para la clasificación, como las prendas superiores (Pullover, Coat, Shirt). Asimismo, se identificó una variabilidad interna significativa dentro de algunas clases, como la "Bag", que requiere que el modelo capture patrones más abstractos.

En la fase de clasificación binaria, donde el objetivo fue distinguir entre camisetas y bolsos (clases 0 y 8) utilizando el algoritmo KNN con $k=3$ y subconjuntos de 3 atributos, se evidenció que la selección de estos atributos tiene un impacto crucial en el rendimiento del modelo. Con los subconjuntos de varios atributos se pudo ver que la cantidad por sí sola no genera buenos resultados predictivos, si no que importa también su distribución sobre la imagen, resultando particularmente efectivas las zonas circundantes al centro y la zona central superior de las imágenes. En contraste, eligiendo otros grupos de píxeles se consiguieron muchos peores resultados. Por ejemplo, el caso de los píxeles de las esquinas, lo que subraya la sensibilidad de KNN a la elección de atributos. Por último, se observó que el número de K influye de mayor manera en los conjuntos de atributos más pequeños. Su influencia es menor en los conjuntos más grandes y en estos el pico de efectividad es alcanzado antes que en los conjuntos más reducidos.

Finalmente, en la clasificación multiclase con árboles de decisión, exploramos cómo la profundidad del árbol influye en su capacidad para modelar la complejidad del problema. La validación cruzada fue fundamental para identificar la profundidad óptima que maximiza la generalización del modelo, evitando el sobreajuste a los datos de entrenamiento. La evaluación final sobre el conjunto held-out reveló que, aunque el modelo de árbol de decisión logra una exactitud razonable para la clasificación de las 10 clases, aún presenta confusiones sistemáticas entre categorías visualmente similares, como "Pullover", "Coat", "T-shirt/top", "Shirt". Esto resalta la inherente dificultad de distinguir entre estas prendas y sugiere áreas de mejora para futuros modelos.

En conclusión, este trabajo ha permitido comprender los desafíos y consideraciones clave en el desarrollo de modelos de clasificación con imágenes, a su vez que nos interiorizó sobre las distintas metodologías y métricas necesarias para evaluarlos y elegirlos.